



**UNIVERSIDAD COMPLUTENSE
MADRID**

Actividad de estadística

Autor: Gerardo Fructuoso Vidal-Aragón

Profesor/a: Conrado Manuel García

Índice

1. Ejercicio 1 – Apartado B	2
2. Ejercicio 1 – Apartado B	6
3. Ejercicio 2 – Apartado A	7
4. Ejercicio 2 – Apartado B	10

1. Ejercicio 1 – Apartado B

Enunciado:

obtener con Python las diferentes medidas de centralización y dispersión, asimetría y curtosis estudiadas. Así mismo, obtener el diagrama de caja y bigotes. Se debe hacer por separado para la sub-muestra de los cráneos del predinástico temprano y para la sub-muestra de los del predinástico tardío. Comentar los resultados obtenidos. Estos comentarios son obligatorios

Resultado:


Medidas periodo temprano:

	Medida	Anchura del cráneo
0	count	30.0
1	mean	131.533333
2	std	0.819307
3	min	130.0
4	25%	131.0
5	50%	131.5
6	75%	132.0
7	max	134.0
8	moda	[131, 132]
9	rango	4
10	varianza	0.671264
11	CoeficientePerson	0.006229
12	CoeficienteFisher	0.645941
13	CoeficienteCurtosis	1.160893

Medidas periodo tardío:

	Medida	Anchura del cráneo
0	count	30.0
1	mean	132.466667
2	std	1.008014
3	min	131.0
4	25%	132.0
5	50%	133.0
6	75%	133.0
7	max	135.0
8	moda	[133]
9	rango	4
10	varianza	1.016092
11	CoeficientePerson	0.00761
12	CoeficienteFisher	0.191826
13	CoeficienteCurtosis	-0.280029

Histograma periodo temprano:



Histograma periodo tardío:




Diagrama de bigotes periodo temprano:





Diagrama de bigotes periodo tardío:



Con las medidas bien calculadas y con los diagramas obtenidos se pueden sacar las siguientes conclusiones:

Distribución temprana:

Para esta distribución temprana se puede observar lo siguiente:

Con los datos de coeficiente de Fisher (0.6459405126888943) al ser mayor que 0, se puede determinar que se tiene una distribución asimétrica positiva, es decir, existe una mayor concentración de valores a la derecha de la media que a su izquierda

Con el coeficiente de curtosis, al ser mayor que 0 (1.160893225745924) nos indica una distribución leptocurtica, es decir, presenta un elevado grado de concentración alrededor de los valores centrales alrededor de la mediana

En el histograma del periodo temprano que tiene una línea en la mediana para así poder observar el comportamiento-forma de la distribución. Se puede observar que se tiene la misma cantidad a la izquierda que a la derecha de la misma, pero se ve que las de la derecha son más atípicas y están más alejados (por lo que hemos visto con Fisher).

Además, se puede observar que alrededor de la mediana se concentran la mayoría de los valores

En el gráfico de diagramas de bigotes del periodo temprano se puede observar lo siguiente:

Se tiene un valor atípico alto que es el 134 ya que está alejado de la media.

Por otro lado, la mediana coincide con el cuartil 50% (131.5), con lo que podría decirse que se repiten mucho los valores 132 y 130 y que tienen la misma cantidad de elementos.

Del periodo tardío:

Con los datos de coeficiente de Fisher (0.1918262295493577) al ser mayor que 0, se puede determinar que se tiene una distribución asimétrica positiva, es decir, existe una mayor concentración de valores a la derecha de la media (132.46666666666667) que a su izquierda, pero por menos cantidad que en el caso de temprano.

Con el coeficiente de curtosis, al ser menor que 0 (-0.2800290739337874) nos indica una distribución platicúrtica, es decir, presenta un reducido grado de concentración alrededor de los valores centrales alrededor de la mediana.

En estos casos, al tener valores tan pequeños, no se nota tanto la diferencia como en el caso de la temprana.

En el histograma del periodo tardío que tiene una línea en la mediana para así poder observar el comportamiento-forma de la distribución. Se puede observar que se tiene una mayor cantidad a la derecha que a la izquierda de la media (132.46666666666667) y por eso mismo se ve claro que tiene una distribución asimétrica positiva.


Además, se puede observar que no hay tantos valores alrededor de la mediana, si no que están más separados.

En el gráfico de diagramas de bigotes del periodo tardío se puede observar lo siguiente:

Se tiene un valor atípico alto que es el 135 ya que está alejado de la media.

Por otro lado, la mediana coincide con el cuartil 75%, con lo que podría decirse que se repiten mucho los valores 133.

Comparando ambos periodos:



Comparando ambas muestras se puede observar que el ancho de los cráneos del periodo temprano era ligeramente menor que en el periodo tardío. La diferencia que se ve entre las medianas de estos periodos es de 1,5 mm.

2. Ejercicio 1 – Apartado B

Enunciado:

Determinar si cada una de las dos sub-muestras sigue una distribución normal utilizando el test de Kolmogorov-Smirnov.

Resultado:

Para la prueba de Kolmogorov-Smirnov tendremos:

Ho -> la distribución 1-2 sigue una distribución normal

H1 -> La distribución 1-2 no sigue una distribución normal

Para esta prueba se ha asignado a alfa (α) un valor de 0.05. Se tienen los siguientes resultados:

Resultados de la submuestra 1:

Estadístico: 0.2460415331404474, Valor p: 0.04379464338101191

La submuestra 1 no sigue una distribución normal

Resultados de la submuestra 2:

Estadístico: 0.23809252465886277, Valor p: 0.055727049848177

La submuestra 2 sigue una distribución normal

Muestra1:

Como se puede observar en la submuestra 1, tiene un valor estadístico de 0.246 para un alfa de 0.05 y una muestra de 30. Además, el pvalor es de 0.0437.

Entonces concluimos: a un nivel de confianza del 95% existe suficiente evidencia para rechazar la H0 con lo que la muestra 1 no sigue una distribución normal

Muestra2:

Como se puede observar en la submuestra 2, tiene un valor estadístico de 0.238 para un alfa de 0.05 y una muestra de 30. Además, el pvalor es de 0.055.

Entonces concluimos: a un nivel de confianza del 95% no existe suficiente evidencia para rechazar la H0 con lo que la muestra 2 sigue una distribución normal

3. Ejercicio 2 – Apartado A

Enunciado:

Con los mismos datos del ejercicio anterior, obtener un intervalo de confianza (de nivel 0.9, de nivel 0.95 y de nivel 0.99) para la diferencia entre las medias de la anchura de la cabeza en ambos periodos históricos. Interpretar los resultados obtenidos y discutirlos en función del test de normalidad del ejercicio anterior. La interpretación debe ser rigurosa desde el punto de vista estadístico y también marcada por el story telling, es

decir, comprensible desde el punto de vista de las variables respondiendo a la pregunta ¿en qué época la cabeza era más ancha?

Resultado:

Condiciones para poder abordar este problema:

1. Definir si las muestras son independientes – en el apartado b nos indican que son independientes
2. Varianzas poblacionales desconocidas
3. Demostrar si estas son iguales o diferentes

De las 3 condiciones nos falta demostrar si las varianzas poblacionales son iguales o diferentes:

H0: Las muestras poseen varianzas poblacionales iguales $S_1 = S_2$

H1: Las muestras poseen varianzas poblacionales diferentes $S_1 \neq S_2$

Para este ejercicio calculamos los siguientes valores:

- **Grados libertad temprano:** 29.0
- **Grados libertad tardío:** 29.0
- **Alfa dos colas:** 0.05
- **Crítico superior e inferior:** $0.5373999648406917 < F < 1.8608114354760754$

En este último valor tenemos la zona de aceptación para la H0 de varianzas.

Calculamos la F estadística:

F estadística: 0.660633484162896

Como la F estadística se encuentra dentro del rango de aceptación de la H0, gráficamente se puede mencionar que:



Como se puede observar en el gráfico con la obtención de los valores críticos y observados en la prueba, se puede concluir con un intervalo de 90% de confianza que no existe evidencia suficiente para rechazar la hipótesis. Por lo que se aprueba la H_0 ya que se puede concluir que las varianzas son iguales con un nivel de confianza del 90%.

Ahora que sabemos que las muestras son independientes, las varianzas desconocidas y además son iguales, se podría calcular el intervalo de confianza de las diferentes medidas. Como este intervalo depende del Error Srandar Estimado, se tiene que calcular de la siguiente forma:

$$\frac{\sqrt{(n_1 S_X^2 + n_2 S_Y^2) \left[\frac{1}{n_1} + \frac{1}{n_2} \right]}}{\sqrt{n_1 + n_2 - 2}}$$

Con eso, nos faltaría calcular el valor crítico T con grados de libertad $(n_1 + n_2 - 2)$ y un alfa dependiendo del intervalo de confianza. Se obtiene el siguiente resultado:

Intervalo de confianza 90%:

(-1.3365370179152296, -0.5301296487514447)

Intervalo de confianza 95%:

(-1.416177718044257, -0.45048894862241723)

Intervalo de confianza 99%:

(-1.5757582312397633, -0.290908435426911)

Teniendo ya estos intervalos de confianza para la diferencia de medias (X_1 (periodo temprano) – X_2 (periodo tardío)), se puede **concluir** que:

Al no incluirse el 0 en los intervalos, se puede ver que las medias poblacionales son diferentes. Con lo que se puede decir que en el periodo tardío los cráneos son más anchos que en el periodo temprano.

4. Ejercicio 2 – Apartado B

Enunciado:

Utilizar el test t para contrastar la hipótesis de que ambas medias son iguales. Explicar qué condiciones se deben cumplir para poder aplicar ese contraste. Determinar si se cumplen. Admitiremos de forma natural la independencia entre ambas muestras, así que esa condición no hace falta comprobarla.

Resultado:

Para poder abordar con este problema se tiene que dar estas 3 condiciones:

- **Normalidad de los datos:** No se cumple la normalización de los datos para el periodo temprano mientras que para el tardío si
- **Homogeneidad de la varianza:** Se demostró en el ejercicio anterior que las varianzas son homogéneas con prueba F
- **Independencia de las observaciones:** Esto se asume de forma natural según el enunciado

A pesar de no cumplir con las condiciones, como se indica en el enunciado se deben de realizar el test T.

Entonces para el test T, plantearemos nuestras hipótesis:

$H_0 \rightarrow$ Las medias de ambas muestras son iguales ----- $M_0 = M_1$

$H_1 \rightarrow$ Las medias de ambas muestras son diferentes ----- $M_0 \neq M_1$

Calculamos los valores necesarios:

- **alfa medios:** 0.025 -> Al tomar un intervalo de confianza del 95%, calculamos alfa medios (0.05/2)


- **zona de aceptación es:** (-2.001717484145236,2.0017174841452356)
- **grados de libertad:** 58.0

Calculamos el valor T estadístico con estos valores:

- **el valor crítico de T es :** -3.869299739267822

Como se puede ver, el valor crítico de T está fuera de nuestra zona de aceptación. Como esto es así con un intervalo de 95% de confianza, se puede rechazar la H0.

Observándolo gráficamente:



Se puede observar como el valor T observado está muy alejado de los valores críticos, con lo que se puede rechazar la H0. Con lo que se podría decir que los cráneos del periodo temprano son distintos a los del periodo tardío.