

Módulo: Machine Learning

Autores: Inmaculada Gutiérrez, Daniel Gómez, Juan Antonio Guevara

MACHINE LEARNING

Este trabajo está orientado a predecir una variable **binaria** a través de diferentes algoritmos de clasificación.

Normas para la realización del trabajo

- a) El trabajo se hará de forma individual.
- b) La entrega del trabajo consta de dos partes.
 - i) Memoria del trabajo realizado, entregada en **pdf** a través del Campus Virtual. La tarea se evaluará exclusivamente con el contenido de la memoria, que debe ser **autoexplicativa**, incluyendo fragmentos del código empleado si fuera necesario. **No se admitirán memorias enviadas en formato .ipynb** o descargadas de Jupyter (con errores, log y similar).
 - ii) Código en Python, para poder reproducir los resultados, pero no será evaluado).
- c) El trabajo deberá estar **explicado** (no basta con responder a las cuestiones), indicando, si es necesario, el **código utilizado** en el pdf. El trabajo explicado debe ser reproducible, no basta con exponer los resultados. Se valora la claridad de exposición en el informe y la estructura. Puede contener Anexos de datos y gráficos o no, todo según vuestro criterio. Se establece un límite de **20 páginas**.
- d) Se debe usar la matriz de datos proporcionada: *BBDD_ML_TAREA.csv*
- e) Es importante tener en cuenta que cada técnica exige una depuración/preparación de los datos específicos. No es necesario desarrollar este proceso en cada una de las preguntas, pero es imprescindible explicar para cada técnica qué parte de la depuración/preparación es necesaria.

Enunciado

Una empresa de servicios de telecomunicaciones desea construir un modelo predictivo que permita anticipar la pérdida o abandono de clientes. Para ello dispone de un conjunto de datos con múltiples características de uso y comportamiento de sus clientes, representadas mediante variables independientes $V1-V20$, y una variable dependiente Y que codifica si un cliente ha abandonado el servicio o no.

El objetivo principal es desarrollar un sistema de clasificación que determine si un cliente está en riesgo de abandono ($Y = 1$) basándose en sus patrones de consumo y servicio.

El conjunto de datos proporcionado contiene las siguientes variables independientes:

Var	Detalle	Var	Detalle
V1	Estado/región del cliente	V11	Minutos totales de llamadas vespertinas
V2	Duración de la cuenta con la empresa	V12	Número de llamadas vespertinas
V3	Código de área telefónica	V13	Coste total de llamadas vespertinas
V4	Número de teléfono del cliente	V14	Minutos totales de llamadas nocturnas
V5	Plan internacional contratado (sí/no)	V15	Número de llamadas nocturnas
V6	Plan de buzón de voz contratado (sí/no)	V16	Coste total de llamadas nocturnas
V7	Número de mensajes de buzón de voz	V17	Minutos totales de llamadas internacionales
V8	Minutos totales de llamadas diurnas	V18	Número de llamadas internacionales
V9	Número de llamadas diurnas	V19	Coste total de llamadas internacionales
V10	Coste total de llamadas diurnas	V20	Número de llamadas al servicio de atención

$V1-V20$ (atributos descriptivos anonimizados de clientes, correspondientes a métricas de uso de servicio, planes contratados, llamadas, cargos y actividad con servicio de atención), y la variable dependiente Y (riesgo de abandono).

CUESTIONES A RESPONDER

1) Análisis y depuración de datos

Analiza y depura la base de datos proporcionada, documentando de forma clara y justificada cada una de las transformaciones y técnicas de *feature engineering* aplicadas. Explica por qué cada proceso es necesario y cómo contribuye a mejorar el rendimiento de los modelos de predicción.

2) Árbol de decisión

Realiza detalladamente un proceso de búsqueda paramétrica exhaustiva para encontrar el mejor árbol de decisión, utilizando al menos cuatro métodos diferentes de validación. Para el árbol ganador:

- Representa gráficamente su estructura.
- Muestra sus reglas en formato textual de manera clara y comprensible.
- Grafica la importancia de sus variables, indicando cuáles son las más determinantes en la clasificación.

Justifica cada elección metodológica, incluyendo la selección de los criterios de validación y los parámetros ajustados, explicando cómo cada decisión impacta en el rendimiento del modelo.

3) Random Forest y XGBoost

Realiza detalladamente un proceso de búsqueda paramétrica exhaustiva para obtener el mejor modelo de Random Forest y de XGBoost, utilizando Accuracy como métrica principal de evaluación. Documenta y justifica:

- Los parámetros explorados y los criterios de selección del modelo final.
- La comparación del rendimiento de ambos modelos, destacando sus diferencias y ventajas.
- La interpretación de los resultados, incluyendo la importancia de variables si procede, y cualquier observación relevante sobre el comportamiento de los modelos.

4) Comparación global de modelos

Desarrolla un análisis comparativo exhaustivo entre los modelos y procesos seleccionados en los apartados 2) y 3). Compara su rendimiento según las métricas de evaluación empleadas, discute las ventajas e inconvenientes de cada enfoque y argumenta las decisiones metodológicas adoptadas. Concluye con una evaluación crítica de cuál(es) modelo(s) resultan más adecuados para el problema planteado y por qué.